Laporan Praktikum #2

Mata Kuliah	:	Teknologi Big Data
Dosen Pengampu	:	Muhayat, M.IT
Praktikum	:	P2 – **Batch Data Ingestion & Processing with Spark**
Nama Mahasiswa	:	Husna Norgina
NIM	:	230104040056
Kelas	:	TI23B
Link Repo Github	:	https://github.com/husna-norgina/bigdata-technology-praktikum-02
Tanggal Praktikum	:	26-02-2026

A. Tujuan Praktikum

1. Menggunakan Linux environment (WSL) untuk data engineering
2. Mengintegrasikan VS Code dengan WSL
3. Mengelola virtual environment Python
4. Mengimplementasikan batch data ingestion dengan Spark
5. Menerapkan data cleaning & transformation
6. Mendesain struktur Data Lake (Raw, Clean, Curated)
7. Menggunakan format Parquet
8. Menerapkan partitioning strategy
9. Menghasilkan pipeline enterprise-ready

B. Arsitektur Pipeline

CSV Source
↓
Raw Layer
↓
Cleaning & Validation
↓
Transformation
↓
Clean Layer (Parquet)
↓
Curated Layer (Aggregation)
↓
Partitioned Data Lake

Konsep yang digunakan:

- Batch Processing
- Distributed Computing
- Medallion Architecture
- Columnar Storage
- Partition Pruning

C. Output

1. Screenshot Eksekusi Spark dan Proses Cleaning Data

```
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project/data/raw$ cd ~/bigdata-project
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$ pwd
/home/husna/bigdata-project
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$ python scripts/batch_pipeline_enterprise.py
========================================
 ENTERPRISE BATCH PIPELINE STARTED
========================================
WARNING: Using incubator modules: jdk.incubator.vector
Using Spark's default log4j profile: org/apache/spark/log4j2-defaults.properties
26/03/04 04:22:33 WARN Utils: Your hostname, LAPTOP-VNJDLGM1, resolves to a loopback address: 127.0.1.1; using 10.255.255.
254 instead (on interface lo)
26/03/04 04:22:33 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another address
Using Spark's default log4j profile: org/apache/spark/log4j2-defaults.properties
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
26/03/04 04:22:34 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java clas
ses where applicable
Spark Session Initialized
Spark Version: 4.1.1
----------------------------------------
Loading raw dataset...
Total Raw Records : 122400
----------------------------------------
Cleaning data...
Total Cleaned Records : 113274
Data Removed : 9126
----------------------------------------
Applying transformation...
Transformation completed
----------------------------------------
Calculating business metrics...
Aggregation completed
----------------------------------------
```

2. Screenshot Hasil Agregasi dan Status Pipeline Berhasil

```
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$ python scripts/batch_pipeline_enterprise.py
Top 5 Products:
+----------+--------------+
|   product|total_quantity|
+----------+--------------+
|    Tablet|         40898|
|    Laptop|         40654|
|   Monitor|         40629|
|Headphones|         40506|
|     Phone|         40314|
+----------+--------------+

Category Revenue:
+-----------+-------------------+
|   category|      total_revenue|
+-----------+-------------------+
|  Computing|9.475295863000005E7|
|Electronics|9.489349299999984E7|
|Accessories|9.442361856000046E7|
+-----------+-------------------+

----------------------------------------
Saving Clean Layer (Parquet)...
Saving Curated Layer...
Saving Partitioned Data...
----------------------------------------
All data successfully saved.
----------------------------------------
========================================
 PIPELINE COMPLETED SUCCESSFULLY
 Total Execution Time: 42.96 seconds
========================================
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$
```

3. Screenshot Perbandingan Ukuran CSV dan Parquet

```
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$ du -sh data/raw/ecommerce_raw.csv
6.2M    data/raw/ecommerce_raw.csv
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$ du -sh data/clean/parquet/
2.3M    data/clean/parquet/
(venv) husna@LAPTOP-VNJDLGM1:~/bigdata-project$
```

D. Analisis

Berdasarkan hasil implementasi pipeline pada Praktikum 2, proses batch data ingestion dan processing menggunakan Apache Spark telah berhasil dijalankan tanpa error. Gambar 1 menunjukkan proses inisialisasi Spark serta jumlah data mentah dan data setelah proses cleaning. Gambar 2 menampilkan hasil agregasi berupa Top 5 Products dan total revenue per category serta status keberhasilan pipeline. Selanjutnya, Gambar 3 memperlihatkan perbandingan ukuran file antara format CSV dan Parquet sebagai bukti efisiensi storage. Hasil ini menunjukkan bahwa seluruh tahapan pipeline telah berjalan sesuai dengan konsep data engineering yang terstruktur dan sistematis.

1. Batch Processing

Batch Processing merupakan metode pemrosesan data dalam jumlah besar yang dilakukan secara sekaligus dalam satu waktu tertentu, bukan secara real-time. Pada pendekatan ini, data dikumpulkan terlebih dahulu, kemudian diproses secara periodik, seperti harian atau mingguan. Metode ini umum digunakan dalam sistem pelaporan transaksi, rekap penjualan, serta analisis data historis. Dalam Praktikum 2 ini, konsep batch processing diterapkan melalui tahapan load dataset CSV, proses cleaning dan validasi data, transformasi perhitungan nilai transaksi, agregasi metrik bisnis, serta penyimpanan hasil ke dalam Data Lake. Proses ini menunjukkan alur batch pipeline yang terstruktur dan sesuai dengan praktik data engineering di industri.

2. Parquet Lebih Efisien

Hasil pengujian menunjukkan bahwa ukuran dataset mentah berformat CSV sebesar ±6.2 MB, sedangkan setelah dikonversi ke format Parquet ukurannya menjadi ±2.3 MB. Hal ini membuktikan bahwa Parquet lebih efisien dalam penyimpanan data. Parquet menggunakan format columnar storage (berbasis kolom), berbeda dengan CSV yang berbasis baris (row-based). Dengan pendekatan ini, data dapat dikompresi secara otomatis dan hanya kolom yang dibutuhkan saja yang dibaca saat proses analitik. Keunggulan tersebut menjadikan Parquet lebih hemat storage, lebih cepat dalam query analitik, serta menjadi standar industri pada sistem Big Data dan Data Lake modern.

3. Partition Pruning

Partition Pruning adalah teknik optimasi yang memungkinkan sistem hanya membaca partisi data yang relevan berdasarkan kondisi query tertentu. Dalam praktikum ini, data dipartisi berdasarkan kolom category menggunakan metode:

```
.partitionBy("category")
```

Dengan strategi ini, data disimpan dalam struktur folder seperti:

```
category=Electronics/
category=Fashion/
```

Ketika dilakukan analisis pada kategori tertentu, Spark tidak perlu membaca seluruh dataset, melainkan hanya folder partisi yang sesuai. Teknik ini mengurangi I/O, meningkatkan performa pemrosesan, dan sangat penting dalam pengolahan data berskala besar yang kompleks dan dinamis.

4. **Hasil Top 5 Produk**
   Berdasarkan hasil agregasi menggunakan fungsi groupBy() dan sum(), diperoleh lima produk dengan total quantity tertinggi (Top 5 Products). Hasil ini menunjukkan produk-produk yang paling banyak dibeli oleh pelanggan selama periode transaksi yang dianalisis. Analisis Top 5 produk ini penting dalam konteks bisnis karena dapat membantu perusahaan mengidentifikasi produk paling diminati, mengoptimalkan strategi stok barang, serta menyusun strategi promosi berbasis data. Berdasarkan output pipeline yang telah dijalankan, lima produk dengan jumlah pembelian tertinggi adalah Tablet (40.898 unit), Laptop (40.654 unit), Monitor (40.629 unit), Headphones (40.506 unit), dan Phone (40.314 unit). Kelima produk tersebut menunjukkan tingkat permintaan yang relatif tinggi dan konsisten dibandingkan produk lainnya dalam dataset. Informasi ini dapat dimanfaatkan perusahaan untuk meningkatkan pengelolaan inventori, memperkuat strategi promosi pada produk unggulan, serta melakukan analisis lanjutan terkait pola pembelian konsumen.

5. **Insight Bisnis Sederhana**
   Dari hasil perhitungan total revenue per category, dapat diidentifikasi kategori dengan kontribusi pendapatan terbesar. Informasi ini memberikan insight bahwa perusahaan dapat memfokuskan strategi pemasaran, distribusi, dan pengelolaan inventori pada kategori dengan performa terbaik secara lebih efektif dan terarah. Selain itu, rata-rata nilai transaksi per pelanggan (average transaction value) juga dapat dimanfaatkan untuk menganalisis perilaku belanja konsumen dan menentukan segmentasi pelanggan secara lebih akurat dan strategis. Secara keseluruhan, pipeline yang dibangun pada praktikum ini tidak hanya berfungsi secara teknis, tetapi juga menghasilkan data yang siap digunakan untuk pengambilan keputusan berbasis analitik yang terukur dan berkelanjutan.

E. Kesimpulan

Praktikum 2 berhasil mengimplementasikan arsitektur batch data pipeline berbasis Apache Spark dengan pendekatan Medallion Architecture (Raw, Clean, Curated). Proses ingestion, cleaning, transformation, aggregation, serta penyimpanan dalam format Parquet dan strategi partitioning menunjukkan penerapan konsep data engineering secara sistematis dan production-ready. Pipeline ini membuktikan bahwa penggunaan distributed computing, columnar storage, serta partitioning strategy mampu meningkatkan efisiensi penyimpanan dan performa pemrosesan data dalam skala besar. Secara keseluruhan, praktikum ini memberikan pemahaman mendasar mengenai pembangunan pipeline data yang scalable, efisien, dan siap diterapkan dalam lingkungan industri berbasis Big Data.